MACHINE-LEARNING (2)
SÉLECTION DE MODÈLES ET CAS AVANCÉS

Vincent Guigue & Romain Thoreau
prenom.nom@agroparistech.fr

Evaluation(s)

Nombreuses métriques disponibles, pour différentes application

Soit les observations $\{\mathbf{x}_i, y_i\}_{i=1,\dots,n}$, $\quad (\mathbf{x}_i, y_i) \in \mathcal{X} \times \mathcal{Y}$

Les métriques les plus classiques :

- Negative Log-Likelihood (NLL)
- MSE / RMSE : $\mathcal{L} = \frac{1}{n}\sum_i (f(\mathbf{x}_i) - y_i)^2$, $\mathcal{L} = \sqrt{\frac{1}{n}\sum_i (f(\mathbf{x}_i) - y_i)^2}$
- MAPE : $\mathcal{L} = \frac{1}{n}\sum_i \frac{|f(\mathbf{x}_i) - y_i|}{|y_i|}$
  - Et les variantes dans le cas $y_i = 0$ (cf sMAPE)
- Accuracy : $\mathcal{L} = \frac{1}{n}\sum_i \mathbb{1}_{y_i == f(\mathbf{x}_i)}$
- Perceptron/SVM : $\mathcal{L} = \frac{1}{n}\sum_i (-y_i \cdot f(\mathbf{x}_i))_+$ ou $\mathcal{L} = \frac{1}{n}\sum_i (1 - y_i \cdot f(\mathbf{x}_i))_+$

Quelle métrique pour quelle application ? Quelles contraintes sur $\mathcal{X} \times \mathcal{Y}$?

ATTENTION : ne pas confondre *métrique d'évaluation* & *coût à optimiser*

Classification : la matrice de confusion

Cas Binaire :

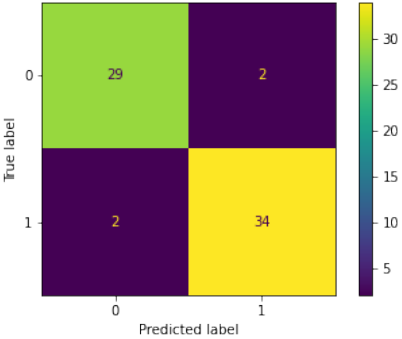

- Compter ce qui est bien classé ou pas,
- Comprendre les confusions

Classification : la matrice de confusion

- Compter ce qui est bien classé ou
- Comprendre les confusions

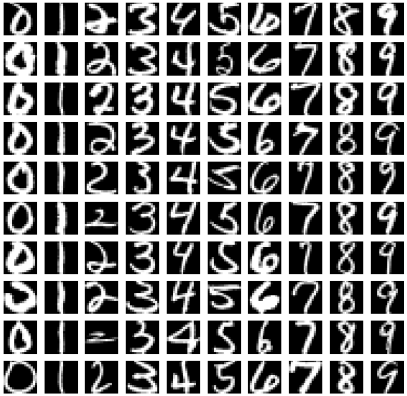

Données USPS :

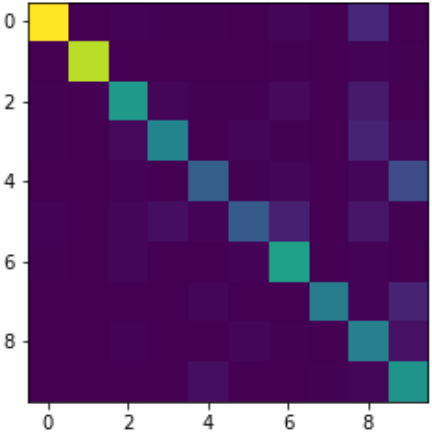

Détection d'évènement (vs bruit de fond)

Classification ⇒ **métrique dédiée à une classe particulière**

- Precision (sensibilité) $\frac{TP}{TP + FP} = \frac{detections\ pertinentes}{detections}$
- Rappel (couverture) $\frac{TP}{TP + FN} = \frac{detections\ pertinentes}{taille\ de\ la\ classe}$
- $F1 = 2 \cdot \frac{precision \cdot rappel}{precision + rappel}$

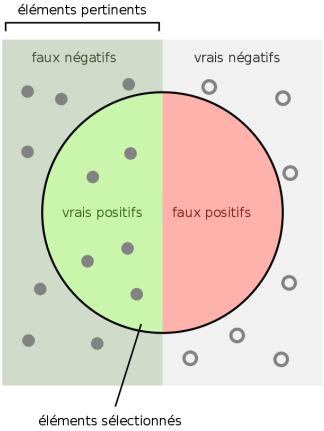

Agrégation sur toutes les classes (dans les cas pertinents)

- macro-moyenne : moyenne des scores des classes (non pondérées)
- micro-moyenne : agrégation au niveau des échantillons (=pondération des classes)

micro VS macro F1, Précision, Rappel, ...

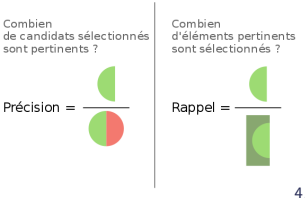

Classification déséquilibrée

Ex : Fraude à la carte bleue : 0.3 pour mille transactions...

- Impact sur les modèles
- Impact sur métriques

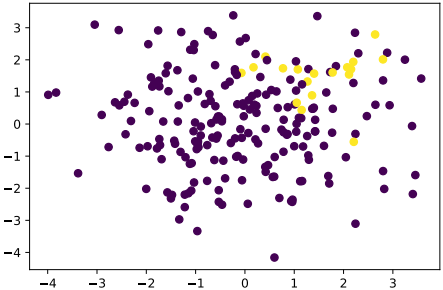

Classification déséquilibrée

Ex : Fraude à la carte bleue : 0.3 pour mille transactions...

- Impact sur les modèles
  - Le modèle prédit que tout est OK
- Impact sur métriques
  - La métrique indique 99.07% de taux de bonne classification !

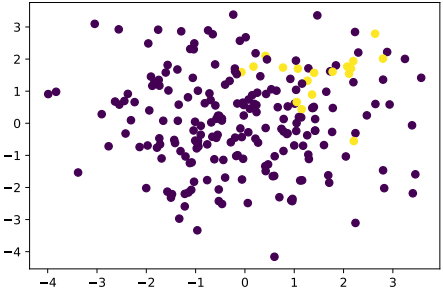

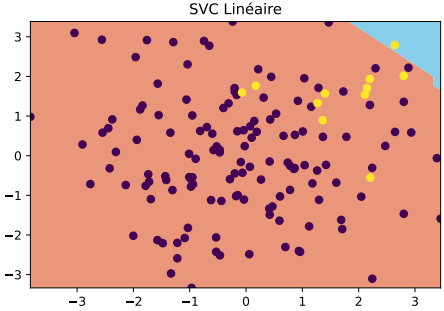

ROC : 1 classifieur ⇒ ensemble des classifieurs biaisés

Courbe ROC : *receiver operating characteristic*

Mesure de la capacité à détecter les évènements sans rajouter de bruit en faisant varier la sensibilité

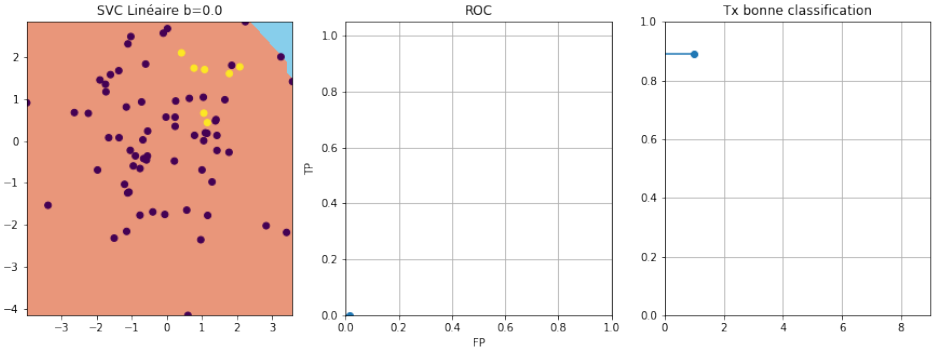

ROC : 1 classifieur ⇒ ensemble des classifieurs biaisés

Courbe ROC : *receiver operating characteristic*

Mesure de la capacité à détecter les évènements sans rajouter de bruit en faisant varier la sensibilité

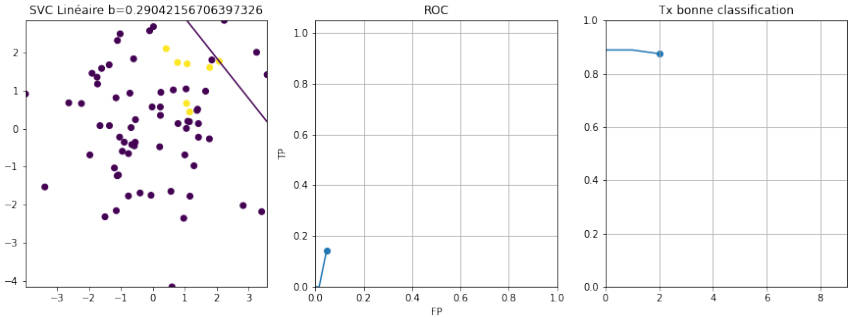

ROC : 1 classifieur ⇒ ensemble des classifieurs biaisés

Courbe ROC : *receiver operating characteristic*

Mesure de la capacité à détecter les évènements sans rajouter de bruit en faisant varier la sensibilité

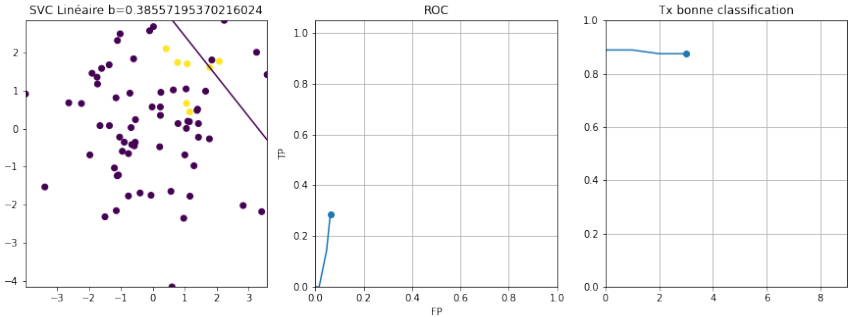

ROC : 1 classifieur ⇒ ensemble des classifieurs biaisés

Courbe ROC : *receiver operating characteristic*

Mesure de la capacité à détecter les évènements sans rajouter de bruit en faisant varier la sensibilité

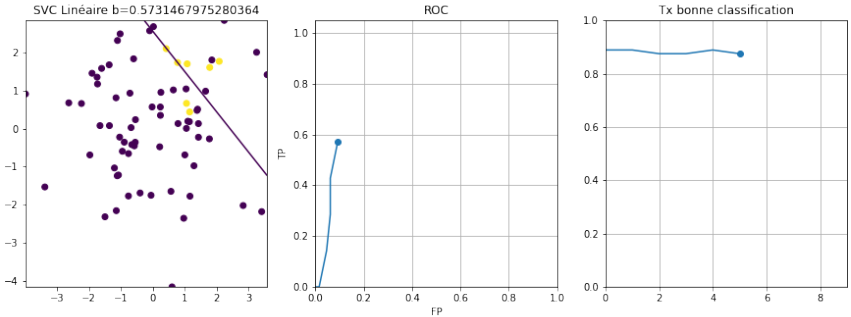

ROC : 1 classifieur ⇒ ensemble des classifieurs biaisés

Courbe ROC : *receiver operating characteristic*

Mesure de la capacité à détecter les évènements sans rajouter de bruit en faisant varier la sensibilité

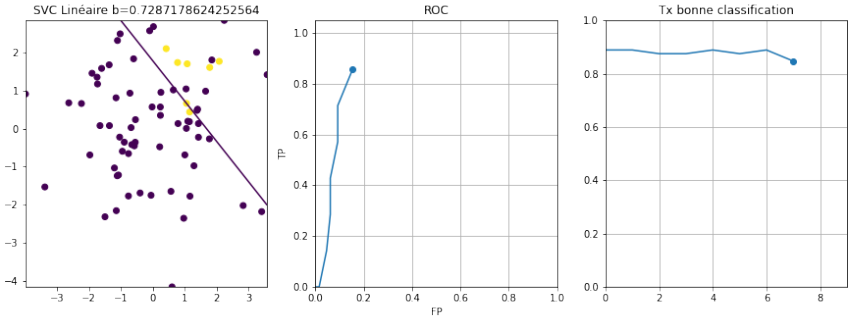

ROC : 1 classifieur ⇒ ensemble des classifieurs biaisés

Courbe ROC : *receiver operating characteristic*

Mesure de la capacité à détecter les évènements sans rajouter de bruit en faisant varier la sensibilité

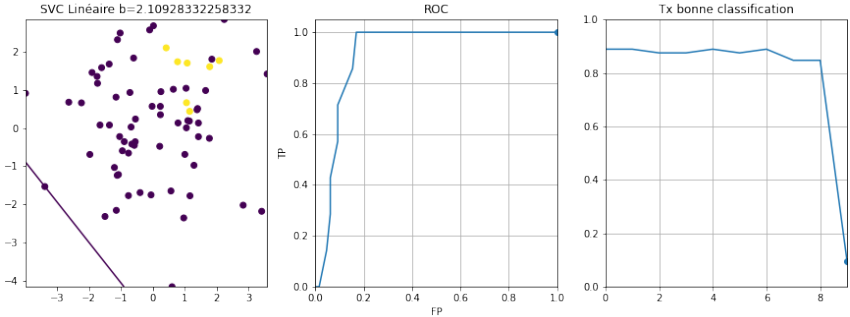

ROC : 1 classifieur ⇒ ensemble des classifieurs biaisés

Courbe ROC : *receiver operating characteristic*

Mesure de la capacité à détecter les évènements sans rajouter de bruit en faisant varier la sensibilité

Indicateurs multiples = difficile à manipuler, expliquer...

- Précision + Rappel ⇒ f1
- ROC ⇒ AUC : Area Under the Curve

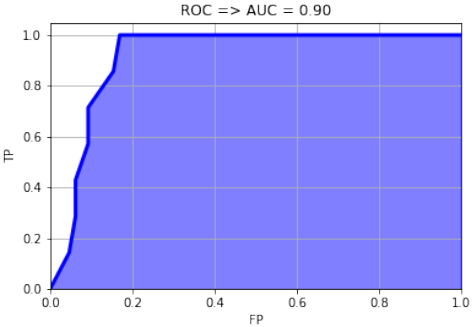

Précision/Rappel (avec tous les biais)

On peut faire la même chose en précision rappel :

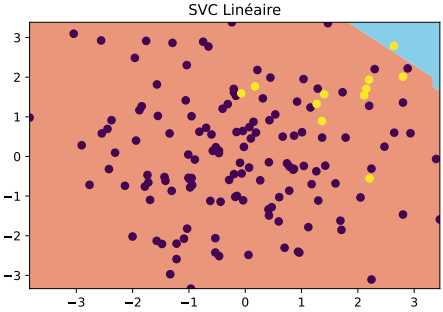

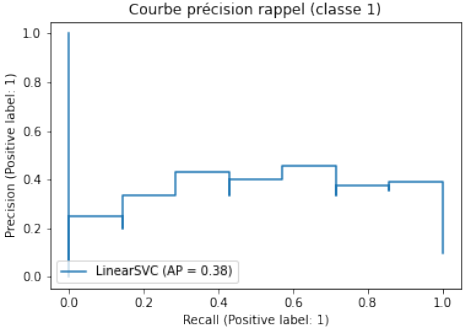

La fonction d'affichage de scikit-learn est encore perfectible... mais on voit les informations importantes.

Autres problèmes, autres métriques

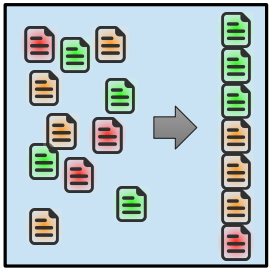

Comment évaluer un modèle d'ordonnancement (=*Ranking*) ?
Critique pour l'accès à l'information : **moteur de recherche**, **systèmes de recommandation**

- Distance d'édition (Levenshtein)
- Mean Reciprocal Rank (MRR) = en combien de coups j'attrape un document d'intérêt
- Favoriser le haut de la liste :
  - Mean Average Precision
  - nDCG
  - ATOP

⇒ A discuter si on fait un séminaire autour de ces thématiques

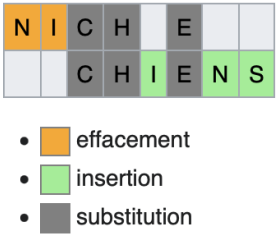

Processus d'évaluation

!! L'évaluation est aussi importante que l'apprentissage !!

- Evaluer sur les données d'apprentissage (=qui ont servi à régler les paramètres)
  $\Rightarrow$ **Tricherie, surestimation des performances**
- Evaluer sur des données vierges = OK

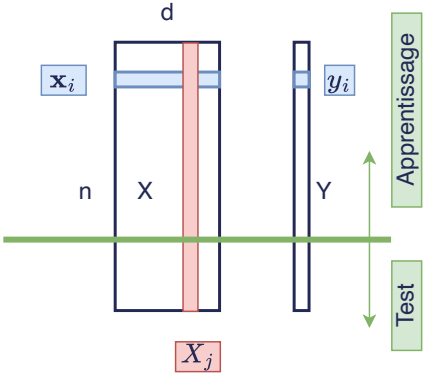

Problème de la répartition entre apprentissage et test

- La validation croisée

Processus d'évaluation

!! L'évaluation est aussi importante que l'apprentissage !!

- Evaluer sur les données d'apprentissage (=qui ont servi à régler les paramètres)
  $\Rightarrow$ **Tricherie, surestimation des performances**
- Evaluer sur des données vierges = OK
- La validation croisée

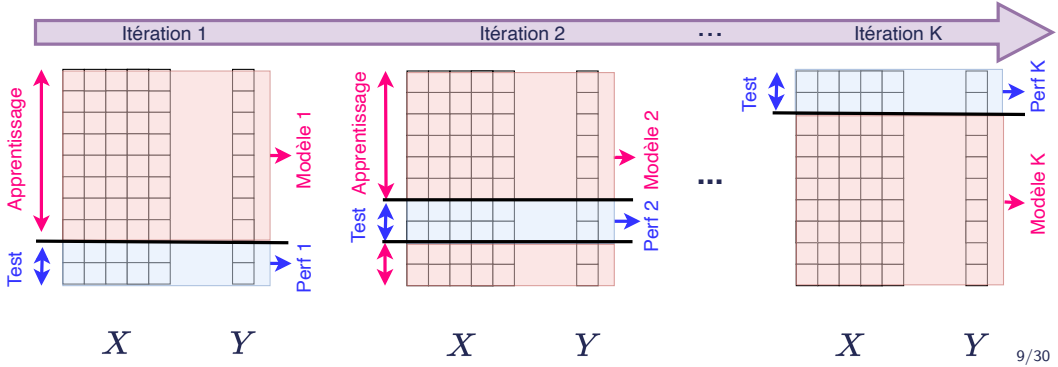

Processus d'évaluation

!! L'évaluation est aussi importante que l'apprentissage !!

- Evaluer sur les données d'apprentissage (=qui ont servi à régler les paramètres) $\Rightarrow$ **Tricherie, surestimation des performances**
- Evaluer sur des données vierges = OK
- La validation croisée

2 options pour l'implémentation :

1. Séparation train-test (itérative pour la validation croisée) + apprentissage + calcul de scores
2. Calcul direct des scores de validation croisée pour un modèle (la boucle, la division des données, l'apprentissage et scoring sont cachés dans la méthode)

Evaluation = clé de sélection des traitements

1. Phase critique de **dialogue avec le client**
   - Identifier les attentes
   - Montrer le niveau de perfromances
2. Outil critique pour la **sélection de modèles**
3. **Significativité** : quand est ce qu'un modèle est *vraiment* meilleur qu'un autre ?
   - Très peu de données (< 50) $\Rightarrow$ stats avancées
   - Beaucoup de données (> 10000, e.g. MNIST) $\Rightarrow$ presque toujours significatif
   - Intermédiaire... $\Rightarrow$ Test de Student sur des validations croisées

- Une étape couteuse mais indispensable
- Parallélisation possible, cf option `n_jobs`

Jusqu'où aller dans la séparation des données ?

Optimisation paramètres / scores validation croisée + publication scores = sur-estimation des performances...

Deux types d'architectures multi-boucles :

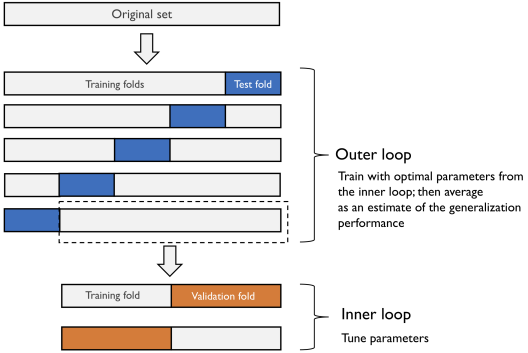

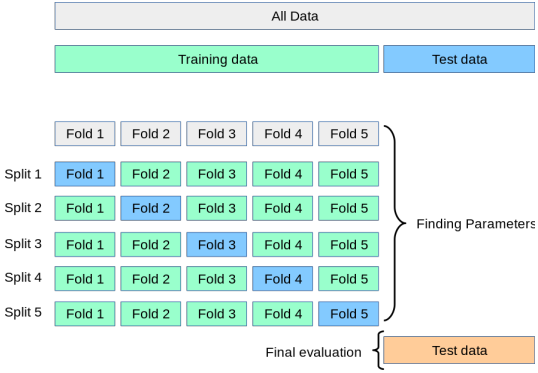

This work by Sebastian Raschka is licensed under a Creative Commons Attribution 4.0 International License.

Sélection de modèles

Sélection de modèles : approche expert

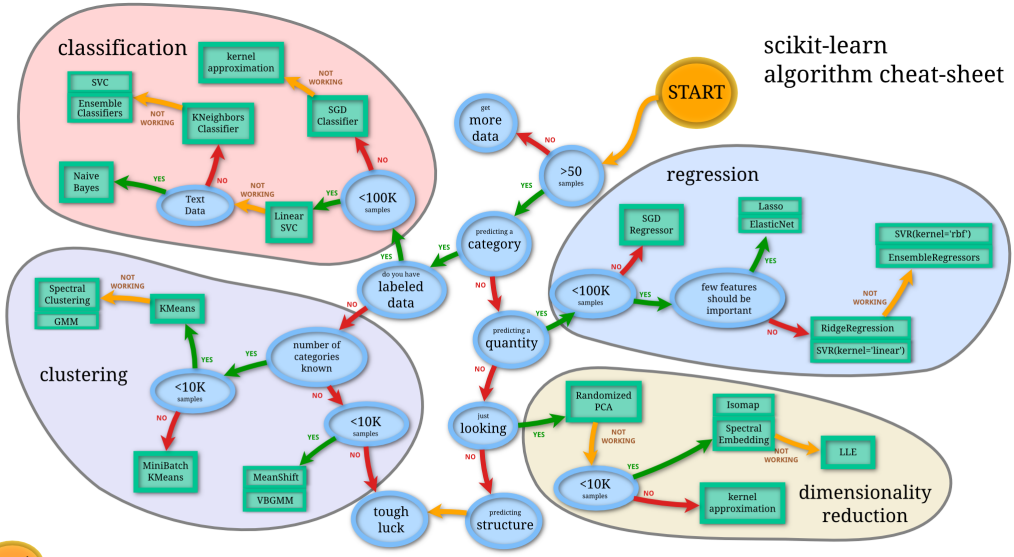

Back

Sélection de modèles : approche théorique

- Bayes Information Criterion (BIC)

$$BIC = \log(n)k - 2log(L), \qquad k, n = \text{nb params/observations}, L = \text{vraisemblance}$$

- Akaike Information Criterion (AIC)

$$AIC = 2k - log(L), \qquad k = \text{nb params}, L = \text{vraisemblance}$$

On cherche un modèle qui minimise un compromis entre complexité et vraisemblance (=adéquation aux données)

$\Rightarrow$ Pour les modélisations probabilistes...

$\Rightarrow$ Ne marche pas en pratique (ou alors pour les modèles où k a peu d'impact, e.g. modèle AR)

Sélection de modèles : approche empirique

[en complément de l'approche expert]

- Liste des modèles de références : Naïve Bayes, Régression logistique, SVM, Decision Tree
- Liste des modèles avancés : Random Forest, Gradient Boosting, réseaux de neurones

Essai + Performance $\Rightarrow$ sélection

Tout en gardant en tête :

1. que les références et l'état de l'art dépendent des applications
2. la puissance des approches ensemblistes

Sélection de modèles : les outils pratiques

Création d'un ensemble de paramètres à tester S

- Boucle `for` + critère pour scorer les S_i
  - apprentissage de modèle + perf. en test
  - validation croisée
  - critère de séparabilité des données (Fisher, ...)
- Grid Search
  - Même procédure généralisée à plusieurs paramètres

En pratique, on tatonne souvent à la main avant de tester finement sur une grille.

- Trouver les paramètres les plus influents / les plus sensibles
- Déterminer la plage de paramètres à explorer

Sélection de caractéristiques

Sélection de caractéristiques/variables/features

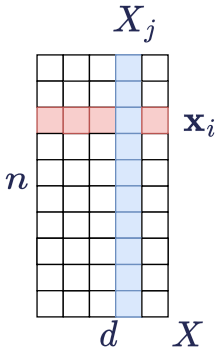

- Individu : $\mathbf{x}_i \in \mathbb{R}^d$
- Caractéristique (*feature*) X_j : variable de description des individus

Sélection de caractéristiques/variables/features

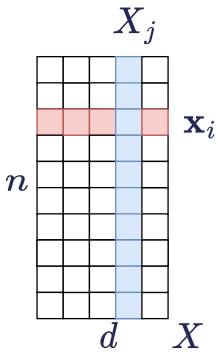

- Individu : $\mathbf{x}_i \in \mathbb{R}^d$
- Caractéristique (*feature*) X_j : variable de description des individus

Croyance naïve

Plus d est grand, plus j'ai de chance de bien répondre à la tâche que je me suis fixée.

Sélection de caractéristiques/variables/features

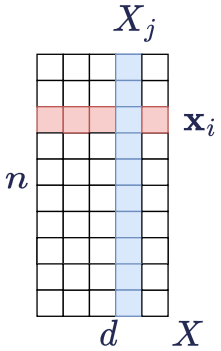

- Individu : $\mathbf{x}_i \in \mathbb{R}^d$
- Caractéristique (*feature*) X_j : variable de description des individus

Contre exemple :

Résolution d'un problème de régression au sens des moindres carrés avec $d > n$:
$X^T X \cdot \mathbf{w} = X^T y$
... Quid des dimensions ?
$X^T X \in \mathbb{R}^{d \times d}$ ... Mais une matrice de rang n : on a en fait n équations indépendantes pour trouver d inconnues $\Rightarrow$ Problème mal posé (probablement) insoluble

Fléau de la dimensionalité - Curse of dimensionality

A classical toy example to illustrate the curse of dimensionality :

Original dataset :

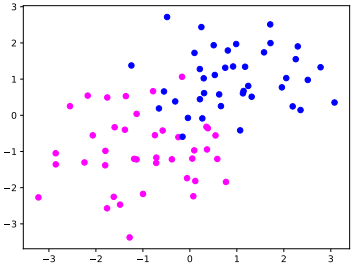

Matrix view

Matrix of raw points

Distance matrix

Matrix of distance between points

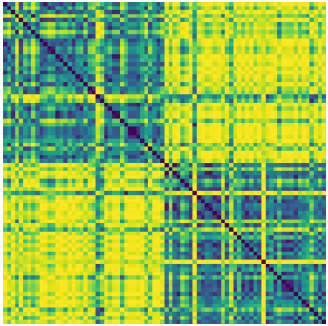

Easy problem / classes are clearly separated

Fléau de la dimensionalité - Curse of dimensionality

A classical toy example to illustrate the curse of dimensionality :

Original dataset :

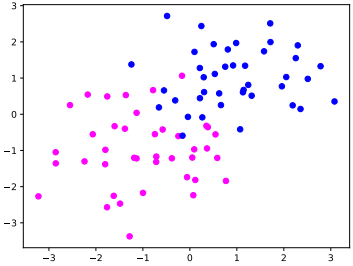

Matrix view

Matrix of raw points

Distance matrix

Matrix of distance between points

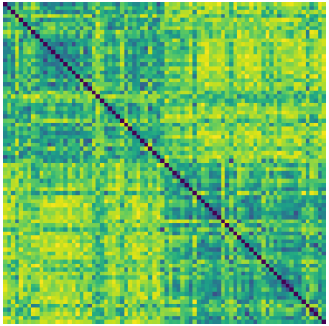

Adding some noisy dimensions in the dataset

Fléau de la dimensionalité - Curse of dimensionality

A classical toy example to illustrate the curse of dimensionality :

Original dataset :

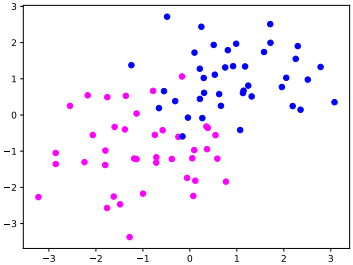

Matrix view

Matrix of raw points

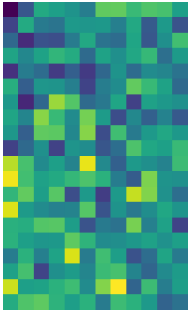

Distance matrix

Matrix of distance between points

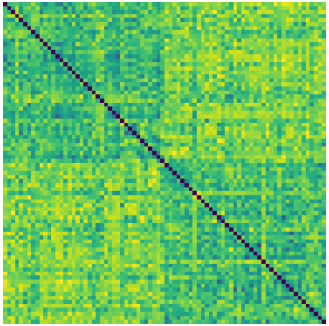

Adding **more** noisy dimensions in the dataset

$\Rightarrow$ Euclidian distance is very sensitive to the dimensionality issue

Fléau de la dimensionalité - Curse of dimensionality

A classical toy example to illustrate the curse of dimensionality :

Basic classifier on those datasets

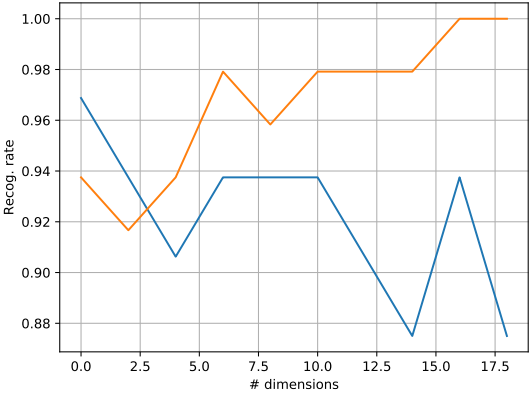

Distances between points in the dataset

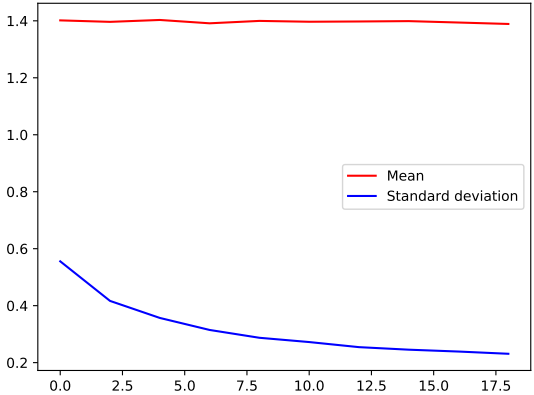

⇒ Learn accuracy ↗, test accuracy ↘ = **overfitting**

⇒ All points tend to lay on an hypersphere (they become equidistant)

Bonne ou mauvaise variable ?

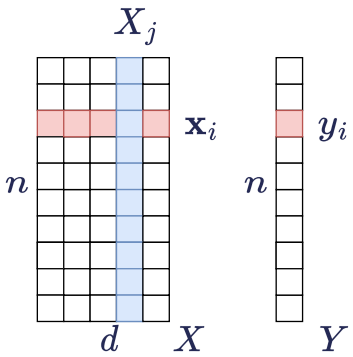

Comment déterminer si X_j est une variable d'intérêt ?

- Calculer le score de corrélation $X_j^T Y$

Bonne ou mauvaise variable ?

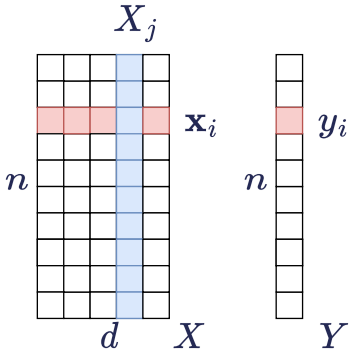

Comment déterminer si X_j est une variable d'intérêt ?

- Calculer le score de corrélation $X_j^T Y$

Ne prend pas en compte les approches non linéaires :
Avec les SVM, on peut facilement construire une variable X_j

- Idéale pour estimer Y
- De corrélation faible ou nulle avec Y

Bonne ou mauvaise variable ?

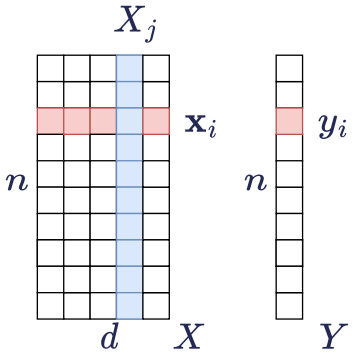

Comment déterminer si X_j est une variable d'intérêt ?

- Calculer le score de corrélation $X_j^T Y$

Quid des variables intéressantes mais corrélées entre elles :

$$X_j^T Y \nearrow\nearrow, \qquad X_k^T Y \nearrow\nearrow \text{ Mais avec : } \qquad X_j \approx X_k$$

Bonne ou mauvaise variable ?

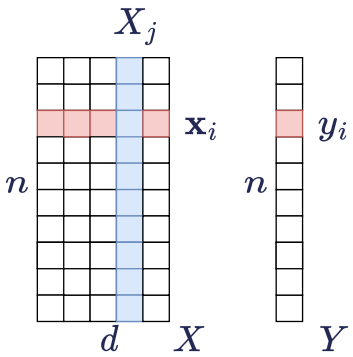

Comment déterminer si X_j est une variable d'intérêt ?

- Calculer le score de corrélation $X_j^T Y$
- Combien de variables conserver ?

Bonne ou mauvaise variable ?

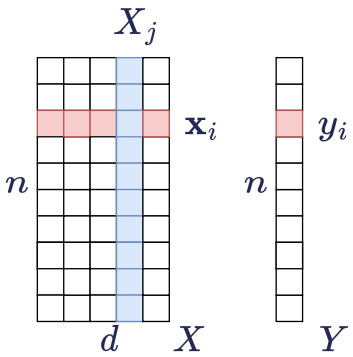

Comment déterminer si X_j est une variable d'intérêt ?

- Calculer le score de corrélation $X_j^T Y$
- Combien de variables conserver ?
- Certaines variables ont-elles un intérêt *combinées* à d'autres ? (retour au cas non linéaire.)

Sélection de caractéristiques

⇒ Un besoin de obtenir de bonnes performances

... mais comment faire ?

Plusieurs grandes familles de solution :

1. Choisir les caractéristiques pertinentes et éliminer les autres
   - à l'aide d'un expert ;
   - en analysant les paramètres des classifieurs (introspection)
   - en testant des combinaisons + scoring (extrospection)
2. Utiliser l'ACP (Analyse en Composantes Principales = PCA en anglais) pour trouver les meilleures combinaisons de variables.
   - Lien avec l'apprentissage non supervisé
3. Essayer d'apprendre les variables à éliminer au cours de l'apprentissage.

(0) Calculer les corrélations entre les descripteurs et la cible

Parfois (souvent), les stratégies les plus naives méritent d'être testées !

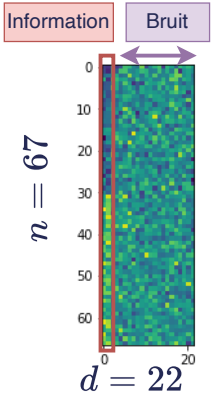

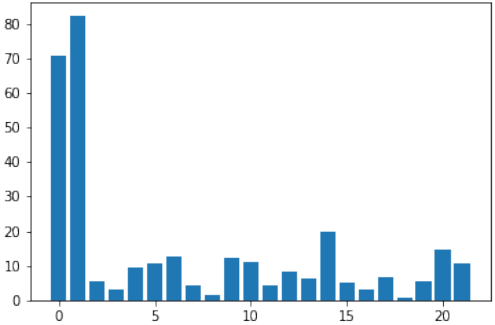

Corrélations entre les variables X_j et la cible y

(1) Utiliser les poids d'un classifieur linéaire

Un classifieur ne sait pas bien gérer les dimensions superflues...
mais la hierarchie des poids peut avoir un sens.

$$f(\mathbf{x}_i) = \sum_{j=1}^{d} w_j x_{ij}, \qquad \Rightarrow w_j \approx \text{importance de } X_j \text{ dans la décision}$$

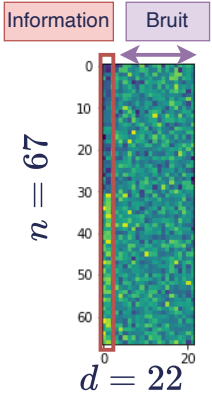

Comment est ce que les w_j vont pondérer les X_j ?

Classifieurs linéaires populaires :

- SVM linéaire
- Régression logistique
- Ridge classification
- ...

(1) Utiliser les poids d'un classifieur linéaire

Un classifieur ne sait pas bien gérer les dimensions superflues...
mais la hierarchie des poids peut avoir un sens.

$$f(\mathbf{x}_i) = \sum_{j=1}^{d} w_j x_{ij}, \qquad \Rightarrow w_j \approx \text{importance de } X_j \text{ dans la décision}$$

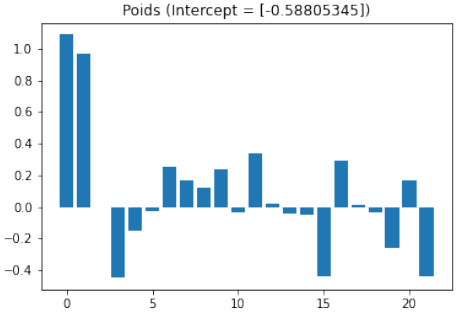

- **Bonne nouvelle :** les poids des caractéristiques importantes sont plus hauts
- **Mauvaise nouvelle :** les autres poids sont assez importants

(1) Exploiter les *feature importance* des forêts

- Les approches ensemblistes sont moins sensible à la dimensionalité
  - Si leurs hypothèses sont assez faibles [$\approx$ forme de régularisation]
- Les méthodes à base d'arbres possèdent aussi des heuristiques de calcul de l'importance des caractéristiques
  - Nombre de fois où la caractéristique est utilisée
  - Nombre de fois où elle est à la racine
  - Nombre de fois où elle détermine les Feuilles
  - Pondération par rapport à l'utilité de l'arbre dans la forêt
  - ...

(1) Sélection Itérative de caractéristiques (par élimination)

Des approches gloutonnes (*greedy*)... Mais très chères !

Recursive Backward Elimination

1. Init. de toutes les caractéristiques : $S = \{X_1, \ldots, X_d\}$
2. Faire d fois :
   - Pour tous les sous-ensembles : $S_i = S/X_i$
     - $p_i = perf(S_i)$ (taux en test, validation croisée, ...)
   - Conserver le meilleur sous ensemble : $S = S_i^\star$

Quel coût ?

(1) Sélection Itérative de caractéristiques (par élimination)

Des approches gloutonnes (*greedy*)... Mais très chères !

Recursive Backward Elimination

1. Init. de toutes les caractéristiques : $S = \{X_1, \ldots, X_d\}$
2. Faire d fois :
   - Pour tous les sous-ensembles : $S_i = S/X_i$
     - $p_i = perf(S_i)$ (taux en test, validation croisée, ...)
   - Conserver le meilleur sous ensemble : $S = S_i^\star$

Quel coût ?

- d iterations

× une itération $= d - 1$ tests (avec d décroissant)

× un test = apprentissage + évalution OU n_{CV} apprentissages + évalutions

Quel coût pour la méthode précédente ?

(1) Sélection Itérative de caractéristiques (par agrégation)

Idem... Mais par agrégation : on part d'un ensemble vide et on remplit

Forward selection

1. Initialisation vide : $S = \emptyset$
2. Faire d fois :
   - Pour tous les sous-ensembles : $S_i = S + X_i$
     - $p_i = perf(S_i)$ (taux en test, validation croisée, ...)
   - Conserver le meilleur sous ensemble : $S = S_i^\star$

(1) Sélection Itérative de caractéristiques (par agrégation)

Idem... Mais par agrégation : on part d'un ensemble vide et on remplit

Forward selection

1. Initialisation vide : $S = \emptyset$
2. Faire d fois :
   - Pour tous les sous-ensembles : $S_i = S + X_i$
     - $p_i = perf(S_i)$ (taux en test, validation croisée, ...)
   - Conserver le meilleur sous ensemble : $S = S_i^\star$

Le prix est (un peu) moindre... Mais pourquoi ?

Backward

- d iterations

× une itération $= d - 1$ tests (avec d **décroissant**)

× un test = apprentissage + évalution OU n_{CV} apprentissages + évalutions

Forward

- d iterations

× une itération $= d - 1$ tests (avec d **croissant**)

× un test = apprentissage + évalution OU n_{CV} apprentissages + évalutions

$\Rightarrow$ Réfléchir à la forme de la courbe $\Rightarrow$ notion d'*early stopping*

(2) ACP/PCA : Analyse en composantes principales

Idée : trouver la combinaison d'axes expliquant au mieux la variance des données...
la valeur propre donne la *force* de l'explication

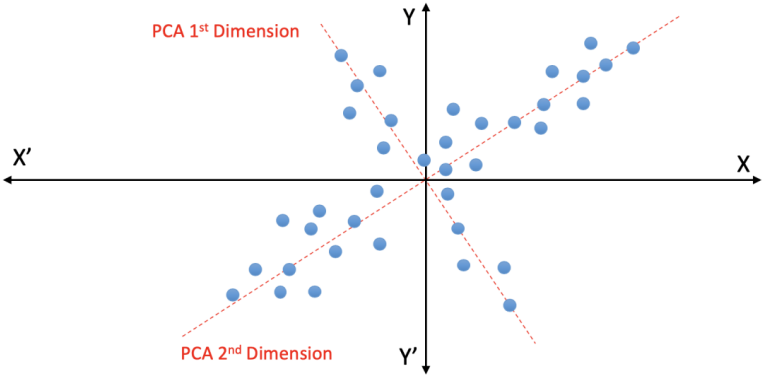

Est ce de la **sélection** ou de la **construction** de caractéristiques ? ?

(2) ACP/PCA : Analyse en composantes principales

Idée : trouver la combinaison d'axes expliquant au mieux la variance des données...

la valeur propre donne la *force* de l'explication

22 dimensions ⇒ 22 valeurs propres + 22 vecteurs propres

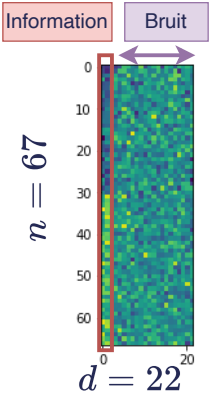

... mais peu de valeurs significatives :

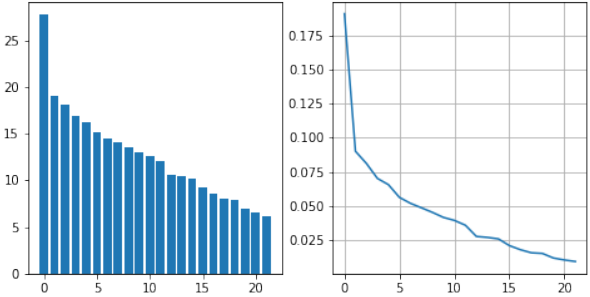

[Valeur prorpre / % de la variance expliquée par chaque val. p.]

(2) ACP/PCA : Analyse en composantes principales

Idée : trouver la combinaison d'axes expliquant au mieux la variance des données...
la valeur propre donne la *force* de l'explication

Tentons des projections :

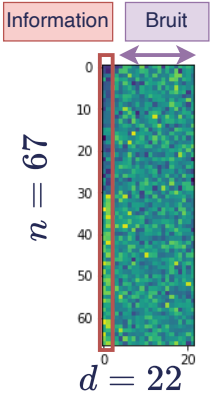

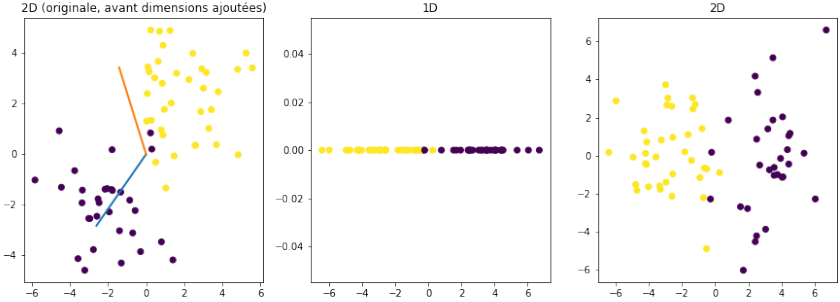

Les axes de la PCA sont orthogonaux... En 22 dimensions !

(2) ACP/PCA : un algo à tout faire

- Variantes pour les réseaux de capteurs
  - Combinaison linéaire de sources
- Visualisation de données

Iris : données 4D
Comment visualiser ?

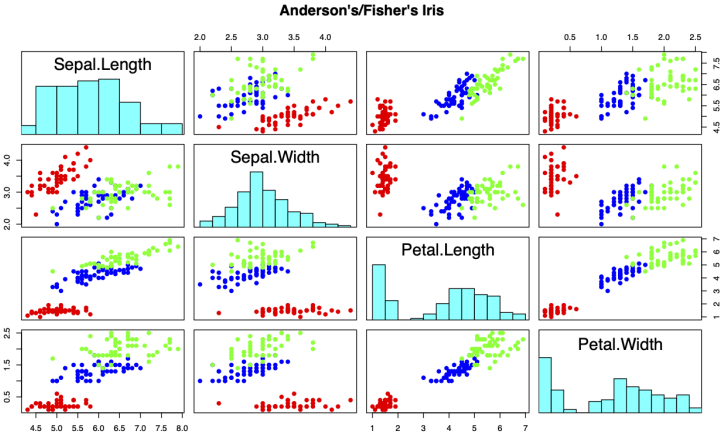

(2) ACP/PCA : un algo à tout faire

- Variantes pour les réseaux de capteurs
  - Combinaison linéaire de sources
- Visualisation de données

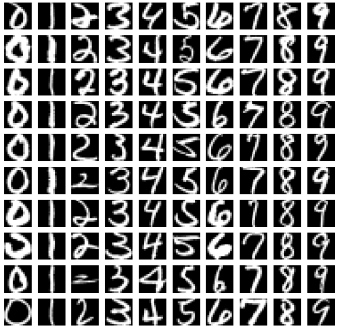

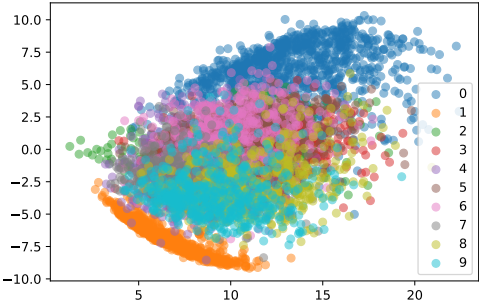

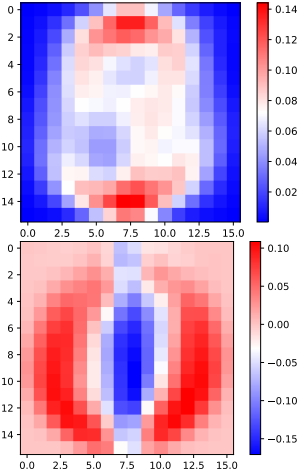

256 dimensions...

(3) Régularisation L2

Idée : apprendre les variables utiles automatiquement (pour une tâche donnée)

Formulation Ridge : $$\mathcal{L} = \sum_{i=1}^{n} \left(\sum_{j=1}^{d} w_j x_{ij} - y_i \right)^2 + C\|w\|^2$$

- Cas limites : $C = 0$ moindres carrés, $C \to \infty \Rightarrow \mathbf{w} = 0$
- Quid des cas intermédiaires ? [notion de chemin de régularisation]

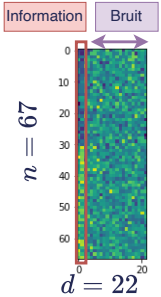

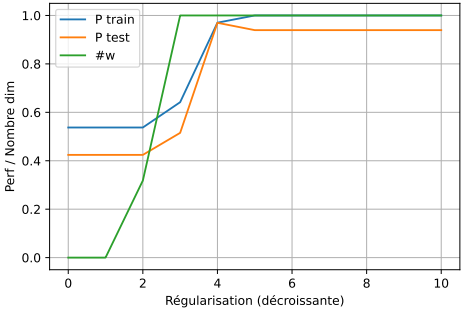

$\Rightarrow$ Peu satisfaisant :
on utilise directement les 22 dimensions

(3) Régularisation L2

Idée : apprendre les variables utiles automatiquement (pour une tâche donnée)

Formulation Ridge : $$\mathcal{L} = \sum_{i=1}^{n} \left(\sum_{j=1}^{d} w_j x_{ij} - y_i \right)^2 + C\|w\|^2$$

- Cas limites : $C = 0$ moindres carrés, $C \to \infty \Rightarrow \mathbf{w} = 0$
- Quid des cas intermédiaires ? [notion de chemin de régularisation]

Explications en revenant sur le gradient :

$\nabla_1 = 2X^T(X\mathbf{w} - Y)$, MAJ : $\mathbf{w} \leftarrow \mathbf{w} - \varepsilon\nabla_1$

$\nabla_2 = 2\mathbf{w}$, MAJ : $\mathbf{w} \leftarrow \mathbf{w} - \nabla_2 = \mathbf{w} \cdot (1 - 2\varepsilon)$ Affaiblissement des poids $\neq$ annulation

(3) Régularisation L1

Idée : apprendre les variables utiles automatiquement (pour une tâche donnée)

LASSO : $$\mathcal{L} = \sum_{i=1}^{n} \left(\sum_{j=1}^{d} w_j x_{ij} - y_i \right)^2 + C\|w\|_1 = \sum_{i=1}^{n} \left(\sum_{j=1}^{d} w_j x_{ij} - y_i \right)^2 + C \sum_{j=1}^{d} |w_j|$$

- (Mêmes) cas limites : $C = 0$ moindres carrés, $C \to \infty \Rightarrow \mathbf{w} = 0$

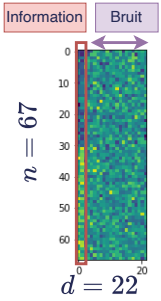

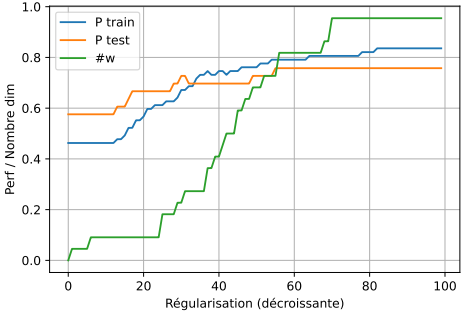

$\Rightarrow$ Bien sur les variables...
Perf. moins bonnes (difficile à régler...)

(3) Régularisation L1

Idée : apprendre les variables utiles automatiquement (pour une tâche donnée)

LASSO : $$\mathcal{L} = \sum_{i=1}^{n} \left(\sum_{j=1}^{d} w_j x_{ij} - y_i \right)^2 + C\|w\|_1 = \sum_{i=1}^{n} \left(\sum_{j=1}^{d} w_j x_{ij} - y_i \right)^2 + C \sum_{j=1}^{d} |w_j|$$

- (Mêmes) cas limites : $C = 0$ moindres carrés, $C \to \infty \Rightarrow \mathbf{w} = 0$

Explications en revenant sur le gradient :

$\nabla_1 = 2X^T(X\mathbf{w} - Y)$, MAJ : $\mathbf{w} \leftarrow \mathbf{w} - \varepsilon \nabla_1$

$\nabla_2 = \text{sign}(\mathbf{w})$, MAJ : $\mathbf{w} \leftarrow \mathbf{w} - \varepsilon \cdot \text{sign}(\mathbf{w})$

$\Rightarrow$ On cherche bien l'annulation des poids

(3) Régularisation Elastic Net

Elastic net : $$\mathcal{L} = \sum_{i=1}^{n} \left(\sum_{j=1}^{d} w_j x_{ij} - y_i \right)^2 + C_1 \sum_{j=1}^{d} |w_j| + C_2 \|\mathbf{w}\|^2$$

$\Rightarrow$ Combiner la régularisation L1 et L2 pour avoir le confort et les performances du L2 avec la sélection du L1

- Beaucoup plus dur d'explorer deux paramètres ...
- ... Mais en réalité, C_1 est epsilonesque et on ne joue presque que sur C_2

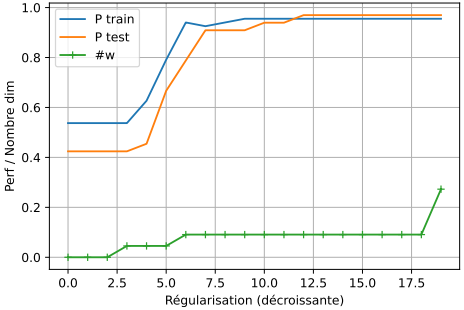

Apprentissage-Test $\Rightarrow$ App/val/test

La multiplication des hyper-paramètres pose problème

Protocole dégradé :

- Pour tout les hyper-paramètres (C, σ, early-stopping...)
  - Apprentissage (X_{app}, y_{app})
  - Evaluation (X_{test}, y_{test})

$\Rightarrow$ Sur-apprentissage du jeu de test avec les hyper-paramètres...

Nouveau protocole :

- Pour tout les hyper-paramètres (C, σ, early-stopping...)
  - Apprentissage (X_{app}, y_{app})
  - Evaluation (X_{val}, y_{val}) $\Rightarrow$ Sélection de modèles
- Evaluation finale : (X_{test}, y_{test})